

Modelos de Aprendizaje Profundo

Ing.Carlos García Lemus (carlos.garcialemus@galileo.edu)
Universidad Galileo

Introducción

El aprendizaje profundo es una de las ramas dentro de la Inteligencia Artificial que busca solventar problemas a través de modelos que se asemejan al aprendizaje humano. Entre ellos se encuentran los modelos de perceptrón multicapa (MLP), redes neurales convolucionales (CNN) y redes neurales recurrentes (RNN), los cuales se han aplicado a tres sets de datos distintos para realizar tareas de aprendizaje supervisado.

Datasets

Según cada tipo de modelo los datasets utilizados son:

- **Costos médicos.** Este dataset trabaja sobre una serie de datos categóricos y numéricos para un problema de regresión resuelto mediante MLP.
- **Clasificación de residuos.** Dataset de imágenes utilizado para problemas espaciales que busca clasificar 6 tipos de residuos distintos para su correcta manipulación, resuelto por medio de CNN.
- **Tweets Análisis de Sentimiento.** Comentarios obtenidos por medio de tweets de distintos usuarios con emoticones que denotan emociones con respecto a la pandemia SARS-CoV-2, analizados de manera secuencial mediante RNN.

MLP

Resolución de problema de regresión a través de una red MLP con regularización mediante dropout.




Figure 1: Arquitectura MLP

CNN

Apoyado en técnicas de transfer learning y aumentado de datos por medio de síntesis de imágenes se utiliza la arquitectura de la red convolucional InceptionV3 para clasificar imágenes en 6 categorías distintas. La arquitectura utilizada es la siguiente:

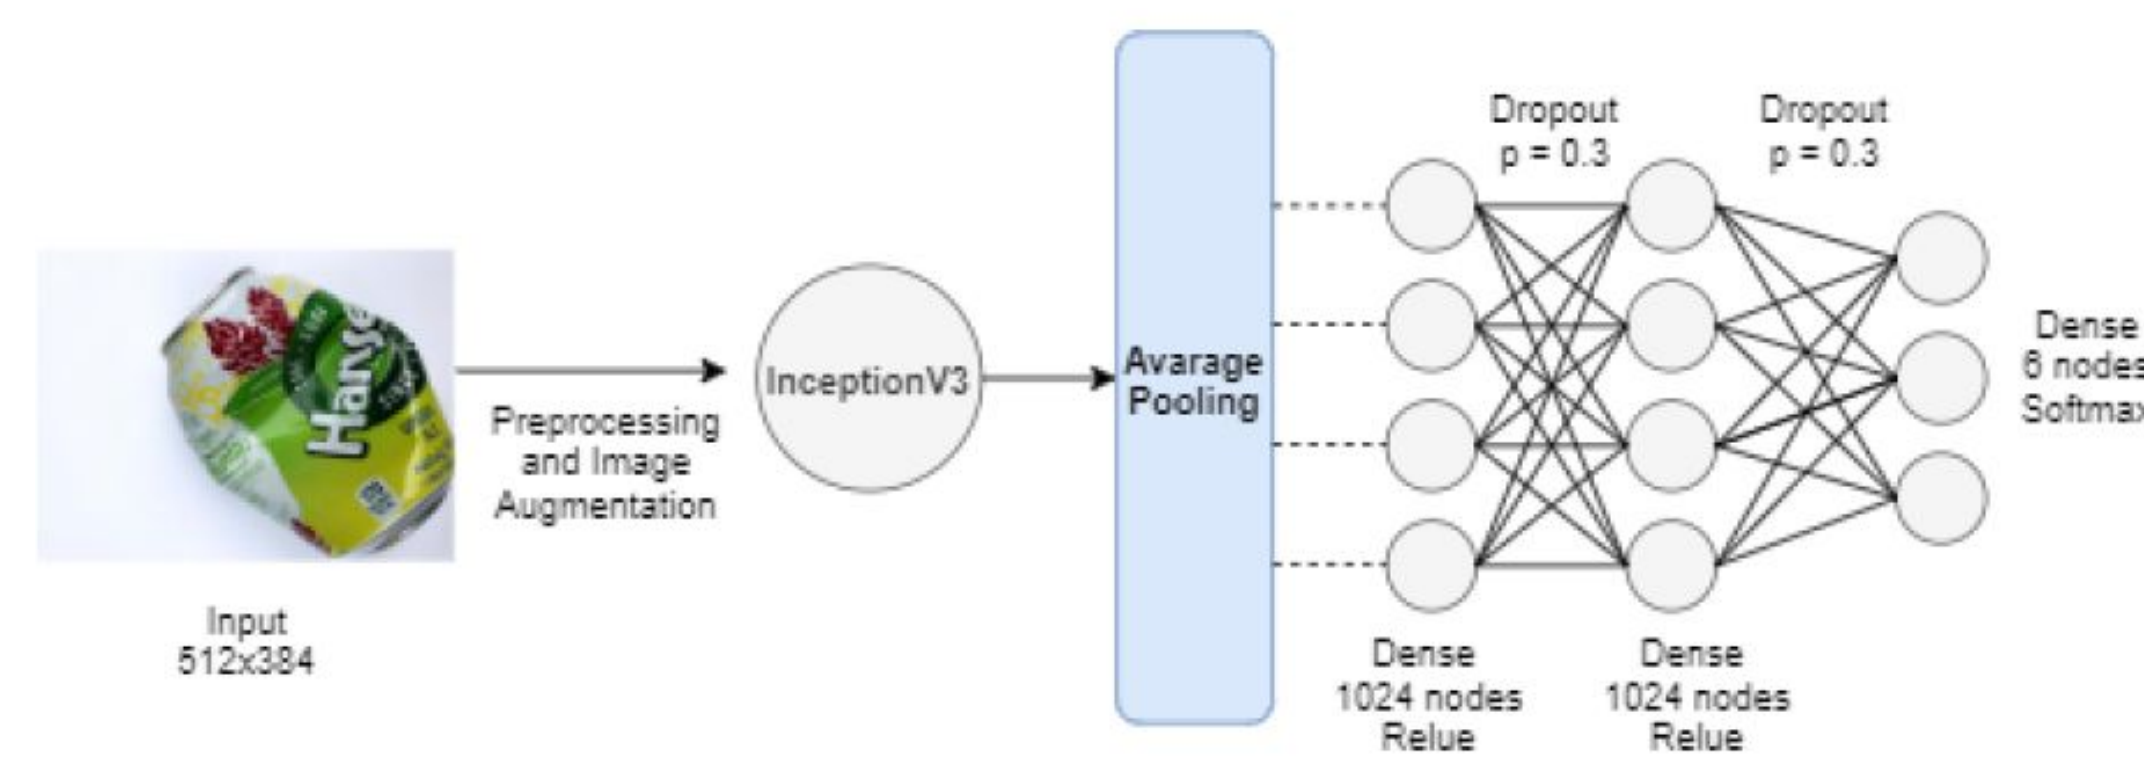


Figure 2: Arquitectura CNN

RNN

Dada las secuencias de texto presentes en los tweets publicados, se extraen los emoticones de los comentarios para definir emociones que son posteriormente utilizadas para el análisis de sentimiento usando NLP, embeddings, y una red RNN.



Figure 3: Mapeo sentimientos-emoticones

Resultados

Cada modelo aplicó un proceso de preprocesamiento distinto, así como un proceso de experimentación iterativo que comprendió el almacenamiento de checkpoints del entrenamiento para conservar los pesos de los parámetros entrenables del modelo, así como el resultado alcanzado para la métrica de evaluación. Dichos resultados son posteriormente utilizados para seleccionar el mejor modelo resultado y definir la construcción del modelo final. Los resultados finales son los siguientes:

Red	Métrica	ID Modelo	Valor
MLP	R^2	1	0.8404
		2	0.8509
CNN	Accuracy	1	65.56%
		2	77.03%
		3	84.69%
		4	85.61%
RNN	Accuracy	1	90.31%
		2	48.58%
		3	93.53%

Tabla 1: Resultados

Conclusiones

A partir de la evaluación de los diferentes modelos se puede concluir:

- El proceso de experimentación se beneficia de una bitácora de control para ordenar y seleccionar los mejores modelos
- Dropout es una técnica sencilla y eficiente de realizar regularización
- Para redes complejas es posible tomar ventaja de transfer learning para acelerar el proceso de aprendizaje
- La realización de embedding de palabras genera una representación más apropiada que beneficia el aprendizaje de los modelos